第一部分.安装 hdfs 集群的具体步骤:

一、首先需要准备 N 台 linux 服务器

先准备 3 台虚拟机: 1 个 namenode 节点 +2 个 datanode 节点

二、修改各台机器的主机名和 ip 地址

主机名: hdp-01 对应的 ip 地址: 192.168.33.61 主机名: hdp-02 对应的 ip 地址: 192.168.33.62 主机名: hdp-03 对应的 ip 地址: 192.168.33.63 主机名: hdp-04 对应的 ip 地址: 192.168.33.64

三、从 windows 中用 MobaXterm_Personal_10.软件进行远程连接

在 windows 中将各台 linux 机器的主机名配置到的 windows 的本地域名映射文件中: c:/windows/system32/drivers/etc/hosts

192.168.33.61 hdp-01 192.168.33.62 hdp-02 192.168.33.63 hdp-03 192.168.33.64 hdp-04

四、配置 linux 服务器的基础软件环境

● 防火墙

关闭防火墙: service iptables stop

关闭防火墙自启: chkconfig iptables off

- 安装 jdk: (hadoop 体系中的各软件都是 java 开发的)
- 1) 打开 sftp 窗口, 然后将 jdk 压缩包拖入 sftp 窗口
- 2) 然后在 linux 中将 jdk 压缩包解压到/root/apps 下
- 3) 配置环境变量: JAVA HOME PATH

vi /etc/profile 在文件的最后,加入:

export JAVA_HOME=/root/apps/jdk1.8.0_60

export PATH=\$PATH:\$JAVA_HOME/bin

- 4) 修改完成后,记得 source /etc/profile 使配置生效
- 5) 检验:在任意目录下输入命令: java-version 看是否成功执行
- 6) 将安装好的 jdk 目录用 scp 命令拷贝到其他机器

- 7) 将/etc/profile 配置文件也用 scp 命令拷贝到其他机器并分别执行 source 命令
- 集群内主机的域名映射配置

在 hdp-01(任意一台虚拟机的名字)上, vi /etc/hosts

```
127.0.0.1 localhost localhost.localdomain localhost4 localhost4.localdomain4
::1 localhost localhost.localdomain localhost6 localhost6.localdomain6
192.168.1.* ***
192.168.1.* ***
192.168.1.* ***
```

然后,将 hosts 文件拷贝到集群中的所有其他机器上

scp /etc/hosts ***:/etc/
scp /etc/hosts ***:/etc/
scp /etc/hosts ***:/etc/

提

示

如果用的是 VMware 虚拟机,则使用以下方法:

如果在执行 scp 命令的时候,<mark>提示没有 scp 命令</mark>,则可以配置一个本地 yum 源来安装充 1、先在虚拟机中配置 cdrom 为一个 centos 的安装镜像 iso 文件

2、在 linux 系统中将光驱挂在到文件系统中(某个目录)

3, mkdir/mnt/cdrom

4、 mount -t iso9660 -o loop /dev/cdrom /mnt/cdrom

5、检验挂载是否成功: Is /mnt/cdrom

- 6、3、配置 yum 的仓库地址配置文件
- 7、yum 的仓库地址配置文件目录: /etc/yum.repos.d
- 8、先将自带的仓库地址配置文件批量更名:

```
[root@hdp-01 ~]# cd /etc/yum.repos.d/
[root@hdp-01 yum.repos.d]# 11
total 24
-rw-r--r-. 1 root root 1991 Aug 4
-rw-r--r-. 1 root root 647 Aug 4
                                               2015 CentOS-Base.repo
                                               2015 CentOS-Debuginfo.repo
2015 CentOS-fasttrack.repo
-rw-r--r--. 1 root root
                                289 Aug
                                           4
                                           4
                                               2015 CentOS-Media.repo
2015 CentOS-Vault.repo
-rw-r--r--. 1 root root
                               630 Aug
-rw-r--r--.
              1 root root 6259 Aug
[root@hdp-01 yum.repos.d]#<u>rename .repo .repo.bak *</u>
[root@hdp-01 yum.repos.d]# 11
total 24
-rw-r--r--. 1 root root 1991 Aug 4
                                               2015 CentOS-Base.repo.bak
-rw-r--r--. 1 root root
-rw-r--r--. 1 root root
                                               2015 CentOS-Debuginfo.repo.bak
2015 CentOS-fasttrack.repo.bak
                               647 Aug 4
                               289 Aug 4
-rw-r--r--. 1 root root
                               630 Aug
                                               2015 CentOS-Media.repo.bak
-rw-r--r--. 1 root root 6259 Aug
                                               2015 CentOS-Vault.repo.bak
```

9、然后,拷贝一个出来进行修改

```
[root@hdp-01 yum.repos.d]# cp CentOS-Media.repo.bak dvd.repo
[root@hdp-01 yum.repos.d]# II
total 28
-rw-r--r-- 1 root root 1991 Aug 4 2015 CentOS-Base.repo.bak
-rw-r--r-- 1 root root 647 Aug 4 2015 CentOS-Debuginfo.repo.bak
-rw-r--r-- 1 root root 289 Aug 4 2015 CentOS-fasttrack.repo.bak
-rw-r--r-- 1 root root 630 Aug 4 2015 CentOS-Media.repo.bak
-rw-r--r-- 1 root root 6259 Aug 4 2015 CentOS-Vault.repo.bak
-rw-r--r-- 1 root root 630 Aug 12 20:04 dvd.repo
[root@hdp-01 yum.repos.d]# vi dvd.repo
```

```
[c6-media]
name=CentOS-$releasever - Media
baseurl=file:///mnt/cdrom
gpgcheck=1
enabled=1
gpgkey=file:///etc/pki/rpm-gpg/RPM-GPG-KEY-CentOS-6
```

- 10、修改完配置文件后,再安装 scp 命令:
- 11, yum install openssh-clients -y

如果是华为云服务器,则直接挂在华为云提供的 centos 镜像,步骤如下

以root用户登录弹性云服务器。

执行以下命令,备份 CentOS-Base.repo 文件。

mkdir -p /etc/yum.repos.d/repo_bak/

mv /etc/yum.repos.d/*.repo /etc/yum.repos.d/repo_bak/

使用 curl 命令下载对应版本的 CentOS-Base.repo 文件,并将其放入/etc/yum.repos.d/目录。

针对华为云当前支持的 CentOS 镜像源版本,使用的 curl 命令分别如下:

CentOS 6

curl -o /etc/yum.repos.d/CentOS-Base.repo
http://mirrors.myhuaweicloud.com/repo/CentOS-Base-6.repo

CentOS 7

curl -o /etc/yum.repos.d/CentOS-Base.repo
http://mirrors.myhuaweicloud.com/repo/CentOS-Base-7.repo

执行以下命令, 生成缓存。

yum makecache

说明:

如果执行命令 yum makecache 后,回显信息为"Another app is currently holding the yum lock",则需执行命令 rm -rf /var/run/yum.pid 删除 yum.pid 文件,然后再执行命令 yum makecache 生成缓存。

如果执行命令 **yum makecache** 后,回显信息为"Error: Cannot retrieve metalink for repository: epel. Please verify its path and try again",则需执行命令 **yum** --disablerepo=epel -y update ca-certificates 更新证书,临时禁用 epel 源。说明

如果执行命令 **yum makecache** 后,回显信息为"Another app is currently holding the yum lock",则需执行命令 **rm -rf /var/run/yum.pid** 删除 yum.pid 文件,然后再执行命令 **yum makecache** 生成缓存。

如果执行命令 yum makecache 后,回显信息为"Error: Cannot retrieve metalink for repository: epel. Please verify its path and try again",则需执行命令 yum --disablerepo=epel -y update ca-certificates 更新证书,临时禁用 epel 源。

五、安装 hdfs 集群

- 1、上传 hadoop 安装包到 hdp-01
- 2、修改配置文件

要点

核心配置参数:

提示

- 1) 指定 hadoop 的默认文件系统为: hdfs
- 2) 指定 hdfs 的 namenode 节点为哪台机器
- 3) 指定 namenode 软件存储元数据的本地目录
- 4) 指定 datanode 软件存放文件块的本地目录

hadoop 的配置文件在: /root/apps/hadoop 安装目录/etc/hadoop/

1) 修改 hadoop-env.sh

export JAVA_HOME=/root/apps/jdk1.8.0_60

2) 修改 core-site.xml

<configuration>

cproperty>

<name>fs.defaultFS</name>

<value>hdfs://hdp-01:9000</value>

</property>

</configuration>

3) 修改 hdfs-site.xml

<configuration>

cproperty>

<name>dfs.namenode.name.dir</name>

<value>/root/dfs/name</value>

</property>

cproperty>

<name>dfs.datanode.data.dir</name>

<value>/root/dfs/data</value>

</property>

</configuration>

4) 拷贝整个 hadoop 安装目录到其他机器

```
scp -r /root/apps/hadoop-2.8.0 hdp-02:/root/apps/
scp -r /root/apps/hadoop-2.8.0 hdp-03:/root/apps/
scp -r /root/apps/hadoop-2.8.0 hdp-04:/root/apps/
```

5) 启动 HDFS

所谓的启动 HDFS, 就是在对的机器上启动对的软件

点

要运行 hadoop 的命令,需要在 linux 环境中配置 HADOOP_HOME 和 PATH 环境变量

vi /etc/profile

提

示

export JAVA_HOME=/root/apps/jdk1.8.0_60

export HADOOP_HOME=/root/apps/hadoop-2.8.0

export PATH=\$PATH:\$JAVA_HOME/bin:\$HADOOP_HOME/bin:\$HADOOP_HOME/sbin

首先,初始化 namenode 的元数据目录

要在 hdp-01 上执行 hadoop 的一个命令来初始化 namenode 的元数据存储目录

hadoop namenode -format

- 创建一个全新的元数据存储目录
- 生成记录元数据的文件 fsimage
- 生成集群的相关标识:如:集群 id——clusterID

然后,启动 namenode 进程(在 hdp-01 上)

hadoop-daemon.sh start namenode

启动完后,首先用 jps 查看一下 namenode 的进程是否存在

然后,在 windows 中用浏览器访问 namenode 提供的 web 端口: 50070

http://hdp-01:50070

然后,启动众 datanode 们(在任意地方)

hadoop-daemon.sh start datanode

6) 用自动批量启动脚本来启动 HDFS

- 2) 配完免密后,可以执行一次 ssh 0.0.0.0
- 3) 修改 hadoop 安装目录中/etc/hadoop/slaves(把需要启动 datanode 进程的节点列入)

hdp-01

hdp-02

hdp-03 hdp-04

- 4) 在 hdp-01 上用脚本: start-dfs.sh 来自动启动整个集群
- 5) 如果要停止,则用脚本: stop-dfs.sh

第二部分. 安装 yarn 集群

yarn 集群中有两个角色:

主节点: Resource Manager 1台 从节点: Node Manager N台

Resource Manager 一般安装在一台专门的机器上

Node Manager 应该与 HDFS 中的 data node 重叠在一起

修改配置文件: yarn-site.xml

cproperty>

<name>yarn.resourcemanager.hostname</name>

<value>hdp-04</value>

</property>

property>

<name>yarn.nodemanager.aux-services</name>

<value>mapreduce_shuffle</value>

</property>

然后复制到每一台机器上

然后在 hdp-04 上,修改 hadoop 的 slaves 文件,列入要启动 nodemanager 的机器 然后将 hdp-04 到所有机器的<mark>免密</mark>登陆配置好

然后,就可以用脚本启动 yarn 集群:

sbin/start-yarn.sh

停止:

sbin/stop-yarn.sh

启动完成后,可以在 windows 上用浏览器访问 resourcemanager 的 web 端口:

http://hdp-04:8088

看 resource mananger 是否认出了所有的 node manager 节点

第三部分. zookeeper 集群搭建

修改 conf/zoo.cfg

The number of milliseconds of each tick

tickTime=2000

The number of ticks that the initial

synchronization phase can take

initLimit=10

The number of ticks that can pass between

sending a request and getting an acknowledgement

syncLimit=5

the directory where the snapshot is stored.

do not use /tmp for storage, /tmp here is just

example sakes.

dataDir=/root/zkdata

the port at which the clients will connect

clientPort=2181

Set to "0" to disable auto purge feature

#autopurge.purgeInterval=1

server.1=hdp-01:2888:3888

server.2=hdp-02:2888:3888

server.3=hdp-03:2888:3888

配置文件修改完后,将安装包拷贝给 hdp-02 和 hdp-03

接着,到 hdp-01 上,新建数据目录/root/zkdata,并在目录中生成一个文件 myid,内容为 1 接着,到 hdp-02 上,新建数据目录/root/zkdata,并在目录中生成一个文件 myid,内容为 2 接着,到 hdp-03 上,新建数据目录/root/zkdata,并在目录中生成一个文件 myid,内容为 3 启动 zookeeper 集群: zookeeper 集群启动时可写个脚本,运行脚本后,便不需要一台一台的启动了。

脚本请自行编写。

第四部分.hive 安装

一. 最简安装: 用内嵌 derby 作为元数据库

准备工作:安装 hive 的机器上应该有 HADOOP 环境(安装目录, HADOOP_HOME 环境变量)

安装: 直接解压一个 hive 安装包即可

此时,安装的这个 hive 实例使用其内嵌的 derby 数据库作为记录元数据的数据库 此模式不便于让团队成员之间共享协作

二.标准安装:将 mysql 作为元数据库

mysql 安装

- ① 上传 mysql 安装包
- (2) 解压:

[root@mylove ~]# tar -xvf MySQL-5.6.26-1.linux_glibc2.5.x86_64.rpm-bundle.tar

③ 安装 mysql 的 server 包

[root@mylove~]# rpm -ivh MySQL-server-5.6.26-1.linux_glibc2.5.x86_64.rpm 依赖报错:

缺 perl

yum install perl

安装完 perl 后 ,继续重新安装 mysql-server

(可以配置一个本地 yum 源进行安装:

- 1、先在 vmware 中给这台虚拟机连接一个光盘镜像
- 2、挂在光驱到一个指定目录: mount -t iso9660 -o loop /dev/cdrom /mnt/cdrom
- 3、将 yum 的配置文件中 baseURL 指向/mnt/cdrom

)

[root@mylove ~]# rpm -ivh MySQL-server-5.6.26-1.linux_glibc2.5.x86_64.rpm

又出错:包冲突 conflict with

移除老版本的冲突包: mysql-libs-5.1.73-3.el6_5.x86_64

[root@mylove ~]# rpm -e mysql-libs-5.1.73-3.el6_5.x86_64 --nodeps

继续重新安装 mysql-server

[root@mylove ~]# rpm -ivh MySQL-server-5.6.26-1.linux_glibc2.5.x86_64.rpm

成功后,注意提示: 里面有初始密码及如何改密码的信息

初始密码: /root/.mysql secret

改密码脚本: /usr/bin/mysql_secure_installation

④ 安装 mysql 的客户端包:

[root@mylove ~]# rpm -ivh MySQL-client-5.6.26-1.linux glibc2.5.x86 64.rpm

(5) 启动 mysql 的服务端:

[root@mylove ~]# service mysql start

Starting MySQL. SUCCESS!

(6) 修改 root 的初始密码:

[root@mylove ~]# /usr/bin/mysql_secure_installation 按提示

(7) 测试:

用 mysql 命令行客户端登陆 mysql 服务器看能否成功

[root@mylove ~]# mysql -uroot -proot

mysql> show databases;

(8) 给 root 用户授予从任何机器上登陆 mysql 服务器的权限:

mysql> grant all privileges on *.* to 'root'@'%' identified by '你的密码' with grant option;

Query OK, 0 rows affected (0.00 sec)

mysql> flush privileges;

Query OK, 0 rows affected (0.00 sec)

注意点:要让 mysql 可以远程登录访问

最直接测试方法:从 windows 上用 Navicat 去连接,能连,则可以,不能连,则要去 mysql 的机器上用命令行客户端进行授权:

在 mysql 的机器上,启动命令行客户端:

mysql -uroot -proot

mysql>grant all privileges on *.* to 'root'@'%' identified by 'root 的密码' with grant option; mysql>flush privileges;

hive 的元数据库配置

vi conf/hive-site.xml

```
<configuration>
cproperty>
<name>javax.jdo.option.ConnectionURL</name>
<value>jdbc:mysql://localhost:3306/hive?createDatabaseIfNotExist=true</value>
<description>JDBC connect string for a JDBC metastore</description>
</property>
cproperty>
<name>javax.jdo.option.ConnectionDriverName</name>
<value>com.mysql.jdbc.Driver</value>
<description>Driver class name for a JDBC metastore</description>
</property>
cproperty>
<name>javax.jdo.option.ConnectionUserName</name>
<value>root</value>
<description>username to use against metastore database</description>
</property>
cproperty>
<name>javax.jdo.option.ConnectionPassword</name>
<value>root</value>
<description>password to use against metastore database</description>
</property>
</configuration>
```

- 2、上传一个 mysql 的驱动 jar 包到 hive 的安装目录的 lib 中
- 3、配置 HADOOP_HOME 和 HIVE_HOME 到系统环境变量中: /etc/profile
- 4, source /etc/profile
- 5、hive 启动测试

然后用命令启动 hive 交互界面:

[root@hdp20-04~]# hive

三. hive 使用方式

最基本使用方式:

启动一个 hive 交互 shell

bin/hive

hive>

设置一些基本参数,让 hive 使用起来更便捷,比如:

1、让提示符显示当前库:

hive>set hive.cli.print.current.db=true;

2、显示查询结果时显示字段名称:

hive>set hive.cli.print.header=true;

但是这样设置只对当前会话有效,重启 hive 会话后就失效,解决办法:

在 linux 的当前用户目录中,编辑一个.hiverc 文件,将参数写入其中:

vi .hiverc

set hive.cli.print.header=true;

set hive.cli.print.current.db=true;

四. 启动 hive 服务使用

启动 hive 的服务:

[root@hdp20-04 hive-1.2.1]# bin/hiveserver2 -hiveconf hive.root.logger=DEBUG,console

上述启动,会将这个服务启动在前台,如果要启动在后台,则命令如下:

nohup bin/hiveserver2 1>/dev/null 2>&1 &

启动成功后,可以在别的节点上用 beeline 去连接

❖ 方式(1)

[root@hdp20-04 hive-1.2.1]# bin/beeline 回车,进入 beeline 的命令界面

输入命令连接 hiveserver2

beeline> !connect jdbc:hive2//mini1:10000

(hadoop01 是 hiveserver2 所启动的那台主机名,端口默认是 10000)

❖ 方式(2)

启动时直接连接:

bin/beeline -u jdbc:hive2://mini1:10000 -n root

接下来就可以做正常 sql 查询了

五. 脚本化运行

大量的 hive 查询任务,如果用交互式 shell 来进行输入的话,显然效率及其低下,因此,生产中更多的是使用脚本化运行机制:

该机制的核心点是: hive 可以用一次性命令的方式来执行给定的 hql 语句

[root@hdp20-04 ~]# hive -e "insert into table t_dest select * from t_src;"

然后,进一步,可以将上述命令写入 shell 脚本中,以便于脚本化运行 hive 任务,并控制、调度众多 hive 任务,示例如下:

vit order etl.sh

#!/bin/bash

hive -e "select * from db_order.t_order"

hive -e "select * from default.t_user"

hql="create table default.t_bash as select * from db_order.t_order"

hive -e "\$hql"

如果要执行的 hql 语句特别复杂,那么,可以把 hql 语句写入一个文件:

vi x.hql

select * from db_order.t_order;

select count(1) from db_order.t_user;

然后,用 hive -f /root/x.hql 来执行

第五部分. 安装 HBASE

HBASE 是一个分布式系统

其中有一个管理角色: HMaster(一般 2 台, 一台 active, 一台 backup)

其他的数据节点角色: HRegionServer(很多台,看数据容量)

安装准备:

首先,要有一个 HDFS 集群,并正常运行; regionserver 应该跟 hdfs 中的 datanode 在一起

其次,还需要一个 zookeeper 集群,并正常运行

然后,安装 HBASE

角色分配如下:

Hdp01: namenode datanode regionserver hmaster zookeeper

Hdp02: datanode regionserver zookeeper Hdp03: datanode regionserver zookeeper

安装步骤:

1. 安装 zookeeper

自行查阅第三部分

2.安装 hbase

解压 hbase 安装包 修改 hbase-env.sh

```
export JAVA_HOME=/root/apps/jdk1.7.0_67
export HBASE_MANAGES_ZK=false
```

修改 hbase-site.xml

```
<configuration>
    <!-- 指定 hbase 在 HDFS 上存储的路径 -->
    property>
            <name>hbase.rootdir</name>
            <value>hdfs://hdp01:9000/hbase</value>
    </property>
    <!-- 指定 hbase 是分布式的 -->
    cproperty>
            <name>hbase.cluster.distributed</name>
            <value>true</value>
    </property>
    <!-- 指定 zk 的地址, 多个用","分割 -->
    property>
            <name>hbase.zookeeper.quorum</name>
            <value>hdp01:2181,hdp02:2181,hdp03:2181</value>
    </property>
</configuration>
```

修改 regionservers

hdp01 hdp02 hdp03

3. 启动 hbase 集群:

bin/start-hbase.sh

启动完后,还可以在集群中找任意一台机器启动一个备用的 master

bin/hbase-daemon.sh start master

新启的这个 master 会处于 backup 状态

4. 启动 hbase 的命令行客户端

bin/hbase shell

Hbase> list // 查看表

Hbase> status // 查看集群状态 Hbase> version // 查看集群版本

第六部分.Flume 的安装部署

1、Flume 的安装非常简单,只需要解压即可,当然,前提是已有 hadoop 环境上传安装包到数据源所在节点上

然后解压 tar -zxvf apache-flume-1.6.0-bin.tar.gz

然后进入 flume 的目录,修改 conf 下的 flume-env.sh,在里面配置 JAVA_HOME

- 2、根据数据采集的需求配置采集方案,描述在配置文件中(文件名可任意自定义)
- 3、指定采集方案配置文件,在相应的节点上启动 flume agent

先用一个最简单的例子来测试一下程序环境是否正常:

- 1、先在 flume 的 conf 目录下新建一个配置文件(采集方案)
- vi netcat-logger.properties

```
# 定义这个 agent 中各组件的名字
```

a1.sources = r1

a1.sinks = k1

a1.channels = c1

描述和配置 source 组件:r1

a1.sources.r1.type = netcat

a1.sources.r1.bind = localhost

a1.sources.r1.port = 44444

描述和配置 sink 组件: k1

a1.sinks.k1.type = logger

描述和配置 channel 组件,此处使用是内存缓存的方式

a1.channels.c1.type = memory

a1.channels.c1.capacity = 1000

a1.channels.c1.transactionCapacity = 100

描述和配置 source channel sink 之间的连接关系

a1.sources.r1.channels = c1 a1.sinks.k1.channel = c1

2、启动 agent 去采集数据

bin/flume-ng agent -c conf -f conf/netcat-logger.conf -n a1 -Dflume.root.logger=INFO,console